
Convolutional Neural Network untuk mengklasifikasi tingkat keparahan jerawat

Rianto Rianto ¹⁾, Demas Risdho Listianto ²⁾

^{1,2)} Universitas Teknologi Yogyakarta

Jl. Siliwangi Jl. Ring Road Utara, Jombor, Sleman, Daerah Istimewa Yogyakarta 55285

Email: ¹⁾ rianto@staff.uty.ac.id, ²⁾ demas.5211811017@student.uty.ac.id

	Riwayat artikel:	
Received: 03-05-2023	Revised: 18-06-2023	Accepted: 20-06-2023

Abstract

Classification is one of the methods used in medical science, especially for the early detection or classify the disease types. In skin health, classification can be used to predict the type and severity of acne so that the treatment can be determined. This study aims to develop a classification model for the type and severity of acne using Deep Learning with a Convolutional Neural Network (CNN). The labels used in the training data consist of levels 0, 1, and 2, which represent the severity of acne. The classifier model was developed using secondary data from www.kaggle.com with 500 images for each label. The optimizer used in this study was ADAM by comparing the number of epochs starting from 50, 80, and up to 100. The accuracy results in the training data obtained were 0.6363, 0.8783, and 0.9234, respectively.

Keywords: *Acne, CNN, Deep Learning*

Abstrak

Klasifikasi merupakan salah satu metode yang digunakan dalam ilmu medis khususnya untuk deteksi dini ataupun klasifikasi jenis penyakit. Dalam ilmu kesehatan kulit, klasifikasi dapat digunakan untuk memprediksi jenis dan tingkat keparahan jerawat sehingga dapat ditentukan cara pengobatannya. Penelitian ini bertujuan untuk mengembangkan model klasifikasi jenis dan tingkat keparahan jerawat menggunakan *Deep Learning* dengan *Convolutional Neural Network* (CNN). Label yang digunakan dalam data latih terdiri dari level 0, 1, dan 2 yang merepresentasikan tingkat keparahan jerawat. Model pengklasifikasi dikembangkan menggunakan data sekunder yang diperoleh dari www.kaggle.com dengan masing-masing label berjumlah 500 citra. *Optimizer* yang digunakan dalam penelitian ini adalah ADAM dengan membandingkan jumlah *epoch* mulai dari 50, 80, sampai dengan 100. Hasil akurasi dalam data latih yang diperoleh adalah 0.6363, 0.8783, dan 0.9234.

Kata kunci: CNN, *Deep Learning*, Jerawat

Pendahuluan

Pada masa lalu, komputer sebatas digunakan untuk menyelesaikan pekerjaan manusia pada bidang pengolahan kata dan atau angka sederhana. Namun, pada perkembangannya komputer mulai dimanfaatkan dalam dunia pendidikan, bisnis, industri dan juga kesehatan. Dunia kesehatan mulai memanfaatkan komputer sebagai sarana promosi, pengajaran maupun sistem rekomendasi [1] [2]. Perkembangan teknologi kecerdasan buatan dengan hadirnya *deep learning* terbukti telah dapat membantu di bidang kesehatan khususnya pencitraan medis untuk melakukan deteksi dini penyakit [3].

Teknologi mampu membuat komputer dapat mengenali pola, menganalisis data dan kata, sampai dengan menganalisis gambar [4]. *Deep learning* memiliki kemampuan mendeteksi obyek dengan sangat baik. Dalam melakukan prosesnya, terutama yang berhubungan dengan gambar, metode ini didukung oleh *Graphic Processing Unit* (GPU), untuk menghasilkan deteksi yang baik [5]. Hal ini yang menyebabkan *deep learning* banyak digunakan untuk memproses data-data yang berhubungan dengan kesehatan [6].

Salah satu bagian dari *deep learning* adalah *Convolutional Neural Network* (CNN) yang merupakan jenis *neural network* yang telah digunakan di berbagai bidang dengan kinerja yang tinggi [7]. Kinerja yang tinggi ini memicu pengembangan aplikasi di bidang kesehatan kulit dan jerawat [8][9]. Jerawat merupakan permasalahan kulit yang umum dan 85% muncul pada usia 12 s.d. 24 tahun. Pengkategorian terhadap jerawat adalah langkah pertama yang dilakukan oleh dokter untuk memberikan perawatan terhadap kulit berjerawat [10]. Hal ini yang menjadi tujuan penelitian yaitu menciptakan sebuah alat untuk mendeteksi level jerawat sehingga bisa ditentukan perawatan dan pengobatan yang tepat [11].

Meskipun tidak berbahaya tetapi perhatian terhadap jenis jerawat ini menjadi penting karena dapat menurunkan tingkat kepercayaan diri. Penelitian ini bertujuan menciptakan sebuah model pengklasifikasi jenis dan tingkat keparahan jerawat menggunakan *deep learning*. Teknik yang digunakan untuk mendeteksi jenis jerawat ini adalah klasifikasi yaitu memasukkan sebuah obyek baru yang belum diketahui kelasnya ke dalam kelas tertentu [12]. Model yang dikembangkan ini diharapkan dapat membantu mendeteksi jenis-jenis jerawat karena berdasarkan hasil penelitian 75% manusia usia remaja tidak berkonsultasi ke dokter terkait dengan jerawat [13].

Kajian Pustaka

Penelitian mengenai pemanfaatan *deep learning* untuk mendeteksi jenis jerawat sudah banyak dilakukan oleh peneliti sebelumnya. Sebuah penelitian mengenai deteksi jerawat dilakukan dengan menggunakan *deep learning* dengan *framework Tensor Flow* dan Model *Faster R-CNN*. Penelitian ini menarik karena bukan hanya persoalan akurasi yang didapat melainkan membedakan tata laksana

pengujian dengan mempertimbangkan intensitas cahaya saat melakukan proses testing. Uji coba yang dilakukan siang hari di dalam ruangan didapatkan akurasi 71.4%, sementara uji coba siang hari di luar ruangan mencapai akurasi 76.1%, dan uji coba yang dilakukan malam hari hanya mendapatkan akurasi 57.1%. Hasil pengujian ini menunjukkan bahwa intensitas cahaya yang merepresentasikan kualitas gambar sangat berpengaruh terhadap akurasi deteksi [14].

Penelitian lain mengenai deteksi jerawat juga dilakukan menggunakan metode *clustering k-Means*. Penelitian ini bertujuan untuk mendeteksi lesi dan non lesi jerawat sehingga dapat dilakukan tindakan lebih lanjut. Penanda lesi jerawat dilakukan dengan teknik *Region of Interest* (ROI). Namun, metode yang digunakan bukan klasifikasi melainkan *clustering*. Data penelitian diperoleh dari *DermNet New Zealand* kemudian dimodifikasi ke dalam ukuran *pixel* 300 x 300. Namun, hasil penelitian ini masih perlu dilakukan peningkatan akurasinya [15].

Algoritma *Grey Level Co-ocurance Matrix* (GLCM) dan *k-Nearest Neighbour* (*k*-NN) diterapkan dalam sebuah penelitian untuk pengenalan jerawat. Penelitian ini menggunakan enam jenis jerawat yang masing-masing jenis memiliki 30 gambar, sehingga total data yang digunakan 180. Keenam jenis jerawat tersebut adalah jerawat Papula, Pustula, Nodul, Kistik, *blackhead*, dan *whitehead*. Data kemudian dibagi dengan rasio 60%:40%. Penelitian ini menghasilkan akurasi 87.3% [15]. Penelitian lain yang menggunakan GLCM untuk mendeteksi jerawat dilakukan dengan data 120 data latih dan 18 data uji. Namun, penelitian hanya mendapatkan akurasi 56.67%. Hasil ini sangat rendah karena masih kurang dari 70%. Salah satu faktor penyebab rendahnya akurasi adalah minimnya data yang digunakan sehingga jaringan kesulitan membedakan jenis jerawat yang memiliki tingkat kemiripan yang tinggi [16].

Metode GLCM juga dipergunakan untuk klasifikasi jerawat dengan mengidentifikasi tekstur menggunakan nilai-nilai ekstraksi ciri. Ekstraksi ciri dihitung menggunakan jarak antara dua *pixel* dengan orientasi sudut 0, 45, 90, dan 135 derajat. Ciri statistik yang dipergunakan untuk mendeteksi jerawat terdiri dari lima yaitu *contrast*, *correlation*, *dissimilarity*, *energy*, dan *entropy*. Ciri-ciri tersebut dipilih karena memiliki faktor dominan untuk membedakan jenis jerawat. Hasil uji dalam penelitian yang dilakukan ini mendapatkan akurasi 72%. Meskipun sudah di atas 70%, tetapi hasil akurasi ini dirasa masih kurang [17]. Klasifikasi penyebab jerawat juga pernah diteliti dengan menggunakan metode yang sama yaitu GLCM menggunakan fitur *contrast*, *energy*, *correlation*, dan *homogeneity*. Meskipun data yang digunakan relatif kecil tetapi akurasi yang didapatkan dalam penelitian ini cukup besar yaitu 78.50% [18].

Penelitian lain dengan memanfaatkan metode GLCM juga dilakukan dengan menggabungkan metode klasifikasi *Support Vector Machine* (SVM). Pada penelitian ini metode GLCM digunakan untuk melakukan analisis tekstur, sementara

SVM untuk mengklasifikasi. Data yang digunakan dalam penelitian ini 100 gambar untuk proses latih dan 30 gambar untuk proses uji. Terdapat tiga proses utama yang dalam penelitian ini yaitu *pre-processing*, ekstraksi fitur GLCM, dan klasifikasi SVM. Hasil penelitian ini juga dibandingkan dengan metode lain yaitu Viola Jones. Hasil penelitian menunjukkan bahwa gabungan metode GLCM dan SVM lebih unggul dalam akurasi yaitu 86%, sementara Viola Jones hanya 36% [19].

Pengembangan tujuan penelitian yang digagas sebenarnya sudah dilakukan oleh peneliti lain dengan membuat alat bantu bagi dokter kulit bernama “Dermato”. Aplikasi ini dikembangkan berbasis web dengan memanfaatkan beberapa algoritma *deep learning*. Pada awal pembuatannya, aplikasi ini belum memenuhi akurasi yang diharapkan, sehingga perlu dilakukan banyak improvisasi. Hasil penelitian ini menyatakan beberapa hal penting untuk pengembangan klasifikasi jerawat diantaranya tidak akan pernah ada sistem khusus yang dapat mengklasifikasi jerawat ke dalam sub tipenya. Hasil penelitian ini mengindikasikan bahwa peran teknologi hanya sekedar membantu untuk mempermudah deteksi awal [20].

Dari beberapa penelitian yang sudah dilakukan tersebut dapat diurai bahwa peneliti pendahulu mengeksplorasi berdasarkan teknik dan hasil. Secara teknis beberapa peneliti pendahulu menggabungkan dengan metode lain seperti GLCM yang tujuannya adalah untuk mengimprovisasi akurasi, sementara penelitian yang dilakukan lebih menitikberatkan pada sisi teknik dengan pemilihan algoritma, pengujian *epochs*, dan data yang lebih banyak. Isu penggunaan *optimizer* ADAM dalam CNN terkait dengan *epochs* adalah *overfitting* yang diakibatkan oleh *overtraining*, sehingga penentuan jumlah *epochs* yang tepat secara otomatis sangat dibutuhkan [21]. Hal ini dilakukan untuk improvisasi hasil akurasi testing, sehingga tujuan penelitian dapat tercapai.

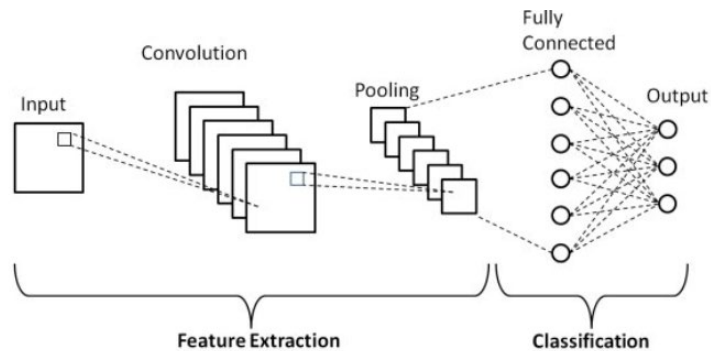
Metode Penelitian

Penelitian yang dilakukan masuk dalam ranah pengolahan citra digital yaitu citra wajah berjerawat. Pengolahan citra didefinisikan sebagai ilmu yang bertujuan dan berkaitan dengan perbaikan kualitas sebuah gambar mulai dari kontras, restorasi, transformasi, dan reduksi sampai dengan penyimpanan hasil. Proses-proses tersebut masuk dalam tahapan data *pre-processing*. Data *pre-processing* bukan hanya sekedar untuk memperbaiki kualitas gambar, tetapi lebih dari itu yaitu untuk meningkatkan hasil akurasi dalam proses latih maupun uji [22].

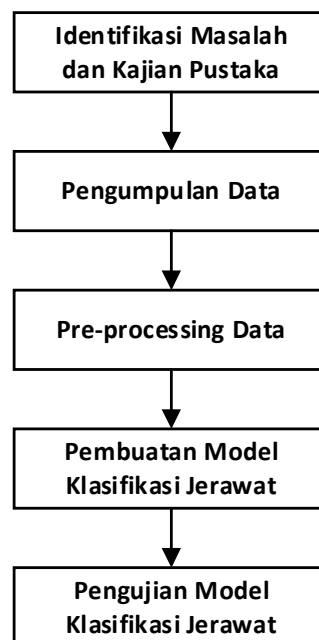
Metode yang digunakan dalam penelitian ini adalah *Convolutional Neural Network* (CNN). Tahapan pertama dalam penelitian yang dilakukan adalah mengidentifikasi masalah yang timbul dalam persoalan jerawat, sembari dilakukan kajian pustaka. Dari hasil identifikasi masalah ditemukan bahwa jerawat dapat dibedakan berdasarkan tingkat keparahannya. Kajian pustaka bertujuan untuk melihat permasalahan serupa yang sudah diselesaikan oleh peneliti pendahulu, sehingga dapat diketahui posisi penelitian yang sedang dilakukan.

Setelah identifikasi masalah dan kajian pustaka dilakukan, dilanjutkan dengan proses pengumpulan data (*data acquisition*). Data yang digunakan dalam penelitian ini adalah data sekunder yang didapatkan dari www.kaggle.com. Setelah dilakukan *pre-processing*, didapatkan data dengan jumlah 1.500 gambar yang terbagi dalam tiga kelas yaitu level 0, 1, dan 2. Proses pembuatan model dilakukan dengan memberikan label pada masing-masing gambar sesuai dengan level. Proses pelabelan didasarkan pada jenis-jenis dan tingkat keparahan yang dalam istilah medis disebut *nodul*, *pustulla*, dan *papula* [23].

Pre-processing data dilakukan dengan melakukan standarisasi data gambar seperti ukuran, kualitas gambar, augmentasi, dan kontras gambar. Hal ini dilakukan karena gambar-gambar yang didapatkan belum semuanya standar. *Pre-processing* dilakukan dalam rangkaian proses latih sekaligus untuk melihat hasil akurasi yang paling baik dengan menghindari *over fitting* maupun *over training*. Skema dasar dari algoritma CNN [24] yang digunakan dalam penelitian ditampilkan pada Gambar 1, sementara tahapan penelitian ditampilkan pada Gambar 2.




Gambar 1 Skema dasar CNN



Gambar 2 Tahapan Penelitian

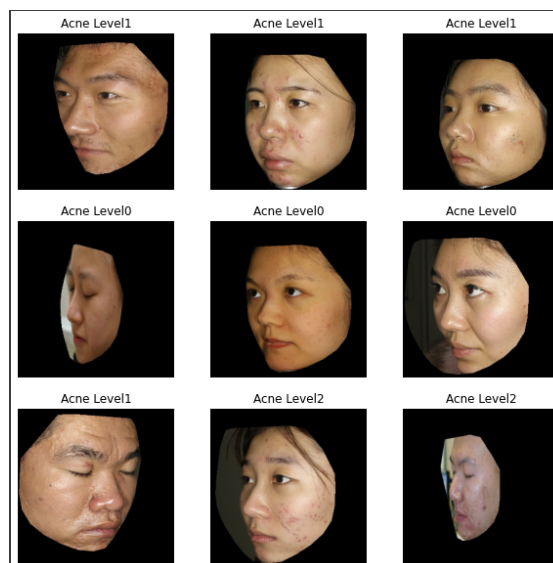
Hasil dan Pembahasan

Jumlah *dataset* yang digunakan dalam penelitian ini berjumlah 1.500 gambar yang terbagi ke dalam tiga kelas yaitu level 0, 1, dan 2. Contoh *dataset* yang merupakan data sekunder ditampilkan dalam Gambar 3.



Gambar 3 Contoh *dataset* berserta labelnya

Dataset yang dicontohkan pada Gambar 3 merupakan klasifikasi jerawat pada masing-masing level. Penerapan skema dasar CNN kemudian diaplikasi untuk melakukan proses pelatihan data sampai dengan mendapatkan hasil akurasi model yang optimal. Setelah dilakukan *pre-processing*, diperoleh hasil gambar seperti yang ditampilkan dalam Gambar 4.



Gambar 4. Hasil *pre-processing* gambar

CNN merupakan pengembangan dari *Multi Layer Perceptron* (MLP). Beberapa layer dalam CNN diantaranya *Convolutional Layer*, *Pooling Layer*, *Fully Connected Layer*, dan *Dropout*. *Convolutional Layer* berfungsi untuk konvolusi seluruh lapisan data yang menghasilkan *feature map* 2D. Hasil dari proses tersebut kemudian diterima oleh *Pooling Layer* menggunakan *Max Pooling Layer*. *Feature map* yang masih berbentuk *array* kemudian diproses menjadi vektor menggunakan *Flatten* dan *Reshape* agar dapat diterima *Fully Connected Layer*. Agar tidak terjadi

Overfitting maka dijalankan proses *Dropout* agar tidak terjadi semua data memiliki persentase yang baik tetapi tidak sesuai pada proses prediksi [25].

Adaptive Moment Estimation (ADAM) yang digunakan dalam penelitian sering mengalami *over fitting* yaitu kondisi dimana akurasi menunjukkan nilai yang tinggi tetapi model tidak dapat memprediksi dengan tepat. Salah satu cara untuk mengantisipasi masalah *over fitting* adalah dengan mencegah *over training*, menggunakan *early stopping*. *Early stopping* memungkinkan untuk melakukan pembatasan jika metrik evaluasi sudah tidak mengalami peningkatan. Hal inilah yang mendasari mengapa penelitian ini juga melakukan pengujian *epoch* dengan maksud untuk mengantisipasi *over fitting* tersebut. *Epoch* adalah proses ketika seluruh data telah melewati seluruh *Neural Network* dalam satu kali putaran [26]. Konfigurasi *Epoch* dalam penelitian yang dilakukan ditampilkan dalam Tabel 1.

Tabel 1 Hasil konfigurasi *epoch*

Epoch	Akurasi
Epoch 50	0.6363
Epoch 80	0.8783
Epoch 100	0.9234

Data pada Tabel 1 menunjukkan hasil akurasi data latih pada masing-masing konfigurasi *epoch* beserta peningkatannya. Selain itu data pada Tabel 1 juga ditunjukkan bahwa semakin tinggi *Epoch* maka akurasi semakin tinggi yaitu 0.9234 pada *epoch* 100, tetapi setelah konfigurasi *epoch* 100 akurasi sudah tidak ada peningkatan.

Proses validasi data dilakukan menggunakan data acak yang tidak dimuat dalam data latih. Uji pertama dilakukan menggunakan data gambar yang secara real dideteksi pada level 0. Hasil uji menunjukkan nilai tingkat kepercayaan sebesar 49.20% pada jenis jerawat level 0, sementara level 1 sebesar 51.43%. Uji validasi pada level 2 menunjukkan tingkat kepercayaan sebesar 87.76%. Hasil uji validasi pada level 0 dan 1 menunjukkan bahwa nilai tingkat kepercayaannya masih rendah. Ada indikasi hal ini disebabkan karena perbedaan gambar level 0 dan level 1 sangat tipis. Hal ini berbeda dengan hasil uji validasi untuk jerawat level 2 yang memang secara signifikan memiliki perbedaan tekstur pada citra jerawat.

Berdasarkan hasil uji validasi tersebut kemudian dilakukan improvisasi dengan menambah kontras gambar untuk jerawat level 0 dan level 1. Kontras gambar disesuaikan dengan menggunakan *library* Pillow dengan nilai *contrast factor* 1.5. Setelah dilakukan pelatihan data ulang dan uji validasi tingkat kenaikan kepercayaan terjadi pada level 0 dan level 1 menjadi 57.60% dan 62.42%. Hasil pengujian validasi ini menunjukkan limitasi penelitian yang masih harus dikembangkan untuk penelitian ke depan, khususnya terkait dengan sumber data yang lebih detail.

Simpulan

Hasil penelitian menyimpulkan bahwa model yang dikembangkan untuk memiliki nilai akurasi 0.9234 atau 92% pada *epoch* 100. Hasil uji validasi juga menunjukkan bahwa model pengklasifikasi yang dikembangkan bekerja dengan baik dengan indikator dapat mengklasifikasikan data baru dengan benar. Penerapan *early stopping* dan *contrast factor* yang digunakan untuk otomatisasi pemberhentian proses latih dan perubahan kontras gambar juga terbukti dapat meningkatkan akurasi model pengklasifikasi. Penelitian yang dapat dilakukan selanjutnya adalah penggunaan *dataset* lokal yang disesuaikan karena untuk citra jenis-jenis jerawat ini dapat berbeda pada masing-masing negara. Selain itu juga perlu improvisasi *hyper* parameter lainnya untuk lebih meningkatkan akurasi model.

Daftar Pustaka

- [1] P. Studi Keperawatan dan Pendidikan Ners and I. Rahmayunia Kartika, "Survey Pemanfaatan Teknologi Informasi Dalam Pembelajaran Mahasiswa Keperawatan," *REAL in Nursing Journal*, vol. 3, no. 1, pp. 40–48, May 2020, doi: 10.32883/RNJ.V3I1.765.
- [2] S. Wahyuni, M. Megasari, and Y. Puspitarini, "Pengaruh Pemanfaatan "PROGRAM SHIFA " (Media Promosi Kesehatan Berbasis IT yaitu SMS Broadcast Tentang Kepatuhan Diet) pada Penderita Diabetes Melitus Tipe 2 di Rumah Sakit Dustira," *Jurnal Kesehatan Budi Luhur : Jurnal Ilmu-Ilmu Kesehatan Masyarakat, Keperawatan, dan Kebidanan*, vol. 12, no. 2, pp. 197–201, Aug. 2019, Accessed: May 02, 2023. [Online]. Available: <http://jurnal.stikesbudiluhurcimahi.ac.id/index.php/jkbl/article/view/70>
- [3] S. Roy *et al.*, "Deep Learning for Classification and Localization of COVID-19 Markers in Point-of-Care Lung Ultrasound," *IEEE Trans Med Imaging*, vol. 39, no. 8, pp. 2676–2687, Aug. 2020, doi: 10.1109/TMI.2020.2994459.
- [4] U. Ramos, M. E. Stivanello, and M. R. Stemmer, "Adaptable Architecture for the Development of Computer Vision Systems in FPGA," *IEEE Latin America Transactions*, vol. 18, no. 12, pp. 2104–2111, Dec. 2020, doi: 10.1109/TLA.2020.9400438.
- [5] E. Naf'an, F. Islami, and G. Gushelmi, "Implementasi Deep Learning Dalam Pendeteksian Kerumunan Yang Berpotensi Melanggar Protokol Kesehatan Covid-19," *JURNAL MEDIA INFORMATIKA BUDIDARMA*, vol. 6, no. 2, pp. 821–826, Apr. 2022, doi: 10.30865/MIB.V6I2.3484.
- [6] B. Khufa Rahmada Aula, C. Fatichah, and D. Purwitasari, "Sistem Rekomendasi pada Forum Kesehatan dengan Pemeringkatan Pertanyaan Serupa Menggunakan Pendekatan Deep Learning," *The Journal on Machine Learning and Computational Intelligence (JMLCI)*, vol. 1, no. 1, Dec. 2021, Accessed: May 02, 2023. [Online]. Available: <https://jmlci.unesa.ac.id/index.php/home/article/view/1>
- [7] S. A. Kawa and M. A. Wani, "Designing Convolution Neural Network Architecture by utilizing the Complexity Model of the Dataset," *Proceedings of the 2022 9th International Conference on Computing for Sustainable Global Development, INDIACom 2022*, pp. 221–225, 2022, doi: 10.23919/INDIACOM54597.2022.9763256.

-
- [8] J. Aguilar *et al.*, "Towards the Development of an Acne-Scar Risk Assessment Tool Using Deep Learning," *2022 IEEE International Autumn Meeting on Power, Electronics and Computing, ROPEC 2022*, 2022, doi: 10.1109/ROPEC55836.2022.10018763.
- [9] N. Pancholi, S. Goel, R. Nijhawan, and S. Gupta, "Classification and Detection of Acne on the Skin using Deep Learning Algorithms," pp. 110–114, Mar. 2022, doi: 10.1109/OCIT53463.2021.00032.
- [10] D. E. Branisteanu *et al.*, "Adult female acne: Clinical and therapeutic particularities (Review)," *Exp Ther Med*, vol. 23, no. 2, pp. 1–7, Feb. 2022, doi: 10.3892/ETM.2021.11074.
- [11] J. Arifianto, "Aplikasi Web Pendeteksi Jerawat Pada Wajah Menggunakan Model Deep Learning Dengan Tensorflow," Jan. 2022, Accessed: May 02, 2023. [Online]. Available: <https://dspace.uui.ac.id/handle/123456789/37886>
- [12] P. B. N. Setio, D. R. S. Saputro, and B. Winarno, "Klasifikasi dengan Pohon Keputusan Berbasis Algoritme C4.5," *PRISMA, Prosiding Seminar Nasional Matematika*, vol. 3, pp. 64–71, Feb. 2020, Accessed: May 02, 2023. [Online]. Available: <https://journal.unnes.ac.id/sju/index.php/prisma/article/view/37650>
- [13] R. T. Lestari *et al.*, "Perilaku Mahasiswa Terkait Cara Mengatasi Jerawat," *Jurnal Farmasi Komunitas*, vol. 8, no. 1, pp. 15–19, Oct. 2021, doi: 10.20473/JFK.V8I1.21922.
- [14] Y. A. Hasma and W. Silfianti, "Implementasi Deep Learning Menggunakan Framework Tensorflow dengan Metode Faster Regional Convolutional Neural Network untuk Pendeteksian Jerawat," *Jurnal Ilmiah Teknologi dan Rekayasa*, vol. 23, no. 2, pp. 89–102, Mar. 2020, doi: 10.35760/TR.2018.V23I2.2459.
- [15] R. L. Hasanah and M. Hasan, "Deteksi Lesi Acne Vulgaris pada Citra Jerawat Wajah Menggunakan Metode K-Means Clustering," *Indonesian Journal on Software Engineering (IJSE)*, vol. 8, no. 1, pp. 46–51, Jun. 2022, doi: 10.31294/IJSE.V8I1.12966.
- [16] Y. F. Achmad, A. Yulfitri, and M. B. Ulum, "Identifikasi Jenis Jerawat Berdasarkan Tekstur Menggunakan GLCM dan Backpropagation," *Jurnal SAINTIKOM (Jurnal Sains Manajemen Informatika dan Komputer)*, vol. 20, no. 2, pp. 139–146, Oct. 2021, doi: 10.53513/JIS.V20I2.4747.
- [17] M. Ramadhani, S. Suprayogi, and H. B. Dyah, "Klasifikasi Jenis Jerawat Berdasarkan Tekstur Dengan Menggunakan Metode Glcm," *eProceedings of Engineering*, vol. 5, no. 1, Apr. 2018, Accessed: May 03, 2023. [Online]. Available: <https://openlibrarypublications.telkomuniversity.ac.id/index.php/engineering/article/view/6049>
- [18] K. Karuniawaty Pakpahan, R. R. Yacoub, E. Kusumawardhani, J. Marpaung, and I. Fitri, "Klasifikasi Penyebab Jerawat Berdasarkan Area pada Wajah Menggunakan Metode Gray Level Co-Occurrence Matrix (GLCM)," *Jurnal Teknik Elektro Universitas Tanjungpura*, vol. 2, no. 1, Aug. 2022, Accessed: May 03, 2023. [Online]. Available: <https://jurnal.untan.ac.id/index.php/jteuntan/article/view/57088>
- [19] P. I. Dewi and A. Musdholifah, "Klasifikasi Jenis Jerawat Menggunakan Support Vector Machine Berdasarkan Hasil Ekstraksi Tekstur Gray-Level Co-Occurrence

- Matrix,” Universitas Gadjah Mada, Yogyakarta, 2020. Accessed: May 03, 2023. [Online]. Available: <http://etd.repository.ugm.ac.id/penelitian/detail/185523>
- [20] K. Naidu, O. Kareppa, S. Menon, C. Bhole, and S. Poojary, “Dermato: A Deep Learning based Application for Acne Subtype and Severity Detection,” *International Conference on Innovative Data Communication Technologies and Application, ICIDCA 2023 - Proceedings*, pp. 569–574, 2023, doi: 10.1109/ICIDCA56705.2023.10100165.
- [21] G. Dhande and Z. Shaikh, “Analysis of epochs in environment based neural networks speech recognition system,” *Proceedings of the International Conference on Trends in Electronics and Informatics, ICOEI 2019*, pp. 605–608, Apr. 2019, doi: 10.1109/ICOEI.2019.8862728.
- [22] N. Z. Munantri, H. Sofyan, and M. Y. Florestiyanto, “Aplikasi Pengolahan Citra Digital Untuk Identifikasi Umur Pohon,” *Telematika : Jurnal Informatika dan Teknologi Informasi*, vol. 16, no. 2, pp. 97–104, Jan. 2020, doi: 10.31315/TELEMATIKA.V16I2.3183.
- [23] R. L. Hasanah, Y. Rianto, and D. Riana, “Identification of Acne Vulgaris Type in Facial Acne Images Using GLCM Feature Extraction and Extreme Learning Machine Algorithm,” *Rekayasa*, vol. 15, no. 2, pp. 204–214, Aug. 2022, doi: 10.21107/REKAYASA.V15I2.14580.
- [24] V. H. Phung and E. J. Rhee, “A High-Accuracy Model Average Ensemble of Convolutional Neural Networks for Classification of Cloud Image Patches on Small Datasets,” *Applied Sciences 2019, Vol. 9, Page 4500*, vol. 9, no. 21, p. 4500, Oct. 2019, doi: 10.3390/APP9214500.
- [25] P. A. Nugroho, I. Fenriana, and R. Arijanto, “Implementasi Deep Learning Menggunakan Convolutional Neural Network (CNN) pada Ekspresi Manusia,” *ALGOR*, vol. 2, no. 1, pp. 12–20, Nov. 2020, Accessed: May 03, 2023. [Online]. Available: <https://jurnal.buddhidharma.ac.id/index.php/algor/article/view/441>
- [26] F. Nashrullah, S. A. Wibowo, and G. Budiman, “The Investigation of Epoch Parameters in ResNet-50 Architecture for Pornographic Classification,” *Journal of Computer, Electronic, and Telecommunication (COMPLETE)*, vol. 1, no. 1, Jul. 2020, doi: 10.52435/COMPLETE.V1I1.51.